

Khảo sát và đánh giá hiệu năng các mô hình Transformer tiền huấn luyện trong bài toán đọc hiểu văn bản tiếng Việt

PhoBERT (word-level) vs XLM-R (subword) trên UIT-ViQuAD 2.0 –
một đánh giá chuẩn đoán

Nguyễn Quang Lâm Trần Trọng Tấn Lê Quang Thi Võ Cẩm Thu
Tháng 9/2026

CS221 – Xử lý ngôn ngữ tự nhiên · GVHD: TS. Đặng Văn Thìn · Trường ĐH Công nghệ Thông tin, ĐHQG-HCM

Bài toán và câu hỏi

Đọc hiểu trích xuất: chỉ ra đáp án *trong* văn bản --- hoặc từ chối

Đầu vào: đoạn văn Wikipedia tiếng Việt + câu hỏi

Đầu ra: một chuỗi *con* của đoạn văn, hoặc $\emptyset$

Ví dụ

“... **Hà Nội** là thủ đô của nước Việt Nam ...”

Hỏi: Thủ đô của Việt Nam là gì? → **Hà Nội**

Hỏi: GDP của Hà Nội năm 2030? → $\emptyset$ (không có đáp án)

UIT-ViQuAD 2.0: 30,44% câu validation **không có đáp án** $\Rightarrow$ mô hình phải biết từ chối.

Hai họ mô hình khác nhau đúng ở khâu tách từ (Buổi 3)

PhoBERT: đơn ngữ, đầu vào đã tách từ

Hà_Nội | là | thủ_đô

XLM-R: đa ngữ, *subword* trên văn bản thô

_Hà | _Nội | _là | _thủ | _đô

Mô hình word-level không thể trả lời nửa từ.

Nếu đáp án cắt ngang “Hà_Nội”, PhoBERT không có cách nào khớp chính xác.

Bốn câu hỏi nghiên cứu

	Câu hỏi	Đo bằng
RQ1	PhoBERT (word-level) có nhạy với ranh giới từ hơn XLM-R (subword)?	trần EM do biên từ · loại lỗi · so sánh cặp McNemar
RQ2	Suy giảm theo độ dài ngữ cảnh / đáp án có khác nhau?	tách nhóm theo độ dài
RQ3	Mô hình thật sự nhận ra câu không có đáp án, hay chỉ thiên lệch về từ chối?	mức sàn “luôn từ chối” · precision/recall từ chối
RQ4	Transformer có vượt baseline TF-IDF ở mọi nhóm?	so từng nhóm

Giả thuyết ghi trước (RQ1): PhoBERT yếu hơn ở ranh giới từ ghép vì lỗi tách từ lan truyền vào mô hình.

Phương pháp

Giao thức: validation chỉ được chấm *một lần*

Tập	Câu	Vai trò	Bốn hệ thống, cùng một harness	
fit (train)	27.049	huấn luyện	Luôn từ chối	mức sàn
dev (5% đoạn văn train)	1.405	chọn epoch	TF-IDF	truy hồi câu (Buổi 4)
validation	3.814	test, chấm 1 lần	XLM-R-base	fine-tune, 384 token
test chính thức	7.301	ẩn nhãn	PhoBERT-base-v2	fine-tune, 256 token
• Chia theo <i>đoạn văn</i>; assert không đoạn văn nào dùng chung • Stress-test <i>chỉ để đánh giá</i> (khung mã cũ trộn 60% vào train) • 1 seed (42), không tìm siêu tham số			Cùng vòng lặp, batch 24, 3 epoch, đáp án tối đa 64 token. PhoBERT <i>b buộc</i> dùng 256 token; 384 token và độ chồng lấp cửa sổ của XLM-R là <i>lựa chọn</i> của nhóm, không phải ràng buộc.	

Đưa PhoBERT vào bài toán trích xuất --- không cần Java

PhoBERT chỉ có *slow tokenizer* $\Rightarrow$ **không có offset** (vị trí ký tự).

Không có offset thì không cắt được đáp án từ văn bản gốc.

Lớp `SegmentedTokenizer`:

1. tách từ bằng `pyvi`
2. căn mỗi từ về khoảng ký tự *trong văn bản gốc*
3. BPE từng từ; mọi mảnh mang chung khoảng của từ

Kiểm thử: giải mã nhãn ra lại đúng đáp án vàng;
25/25 dự đoán là chuỗi con sạch của ngữ cảnh.


Lỗi “sai âm thầm” đã tránh

`decode()` trả về "Hà_Nội"
chuẩn hoá xoá dấu câu $\Rightarrow$ "hànội"
so với vàng "hà nội" $\Rightarrow$ **EM 0, F1 0**

Một đáp án *đúng* bị chấm sai – khung mã cũ mắc lỗi này.

Kiểm định công cụ đo

Bộ stress-test v2: kiểm định *trước* khi dùng



O

vi phạm trên 1.139 mục – *mọi* mục đều chấm được

- 1.139 mục trên 572 ngữ cảnh
- Câu hỏi + đáp án vàng đều do *người* gán (ViQuAD 2.0)
- Biến đổi chỉ dùng luật mà nhãn mới suy ra được
- “Luôn từ chối” chỉ đạt **26,34** điểm

Kiểm bằng máy: offset đúng, đáp án đã mất thật sự, câu hỏi E5 hết dấu, không trùng train.

⇒ Xếp hạng được, dùng để **chẩn đoán**.

Trần EM do biên từ --- đo được mà không cần mô hình

Trên 2.653 câu có đáp án của validation:

1,24%

đáp án cắt ngang một từ (33 câu)

99,25%

EM tối đa của PhoBERT *hoàn hảo*

Đọc từng câu lệch biên:

pyvi dính dấu chấm: CNN. 13

pyvi nối nhầm: Mỹ_Chú chuột 12

Lỗi gán nhãn: “o thời gian” 5


Ranh giới từ ghép thật: bởi_vì **3**

Kênh “không trả lời được nửa từ” lấy đi tối đa 0,75 điểm EM.

Nguồn: results/segmentation_validation.json, results/misaligned_labels.json

Kết quả

Kết quả tổng ở ngưỡng mặc định $\tau = 0$ --- validation, 3.814 câu



	EM	F1
Luôn từ chối	30,44	30,44
TF-IDF	1,05	22,11
XLM-R s42	52,49	61,32
XLM-R s13	53,64	62,18
PhoBERT s42	51,36	63,10
PhoBERT s13	58,94	68,91

PhoBERT – XLM-R (EM, cùng seed):

s42 -1,13 · s13 +5,30

Hai seed, hai câu trả lời khác nhau!

Nguồn: results/eval*_validation.json, results/diagnosis_validation.json

Seed 42, $\tau = 0$: hai hồ sơ kỹ năng *ngược nhau*?

Câu có đáp án (2.653)

+14,89

EM cho PhoBERT

CI [13,08; 16,77] · **66,91** vs 52,02

Câu không có đáp án (1.161)

-37,73

EM (PhoBERT kém hơn)

CI [-40,83; -34,63] · **15,85** vs 53,57

Nhưng PhoBERT từ chối 5,66%, XLM-R từ chối 32,96%

Hai chênh lệch phần lớn là *một*: ai sẵn lòng trả lời hơn. Seed 13 *không* có hai hồ sơ ngược nhau – PhoBERT từ chối 26,38% – nên hình ảnh này là của *một lần chạy*.

Nguồn: results/diagnosis_validation.json, results/thresholds.json

So đúng cách: chọn ngưỡng τ cho từng mô hình trên dev

τ chọn trên dev (1.405 câu tách từ train),
áp **một lần** lên validation

	τ	F1	Từ chối
XLM-R s42	-0,47	61,99	27,77%
XLM-R s13	-0,62	62,68	24,28%
PhoBERT s42	7,86	68,54	24,96%
PhoBERT s13	1,03	68,49	32,14%

+5,82 /
+6,00

EM cho PhoBERT, seed 42 / seed 13
CI theo bài [3,60; 7,72] / [3,30; 8,29]

Phần chia theo loại câu *không* ổn định
giữa hai seed

“Hai hồ sơ ngược nhau” là do một lần chạy lệch hiệu chỉnh

Ở ngưỡng đúng, PhoBERT tốt hơn về tổng ở cả hai seed. Nhưng phần hơn đó là hiệu chỉnh:
xem slide sau.

Vậy PhoBERT có đọc tốt hơn? Không đo được khác biệt.

Phải khớp **cả hai** biến gây nhiễu: cấu hình cửa sổ và lần chạy sục đổ.

PhoBERT s13 vs XLM-R **256/96**, cả hai ổn định, mỗi bên ở τ của mình:

Nhóm câu	Chênh EM	CI 95%
Toàn bộ	+5,85	[3,74; 7,85]
Có đáp án	-0,08	[-2,24; 2,05]
Không có đáp án	+19,38	[16,71; 22,76]

- CI chỉ rộng ± 2 điểm $\Rightarrow$ **không khác biệt**, chứ không phải thiếu dữ liệu

- Toàn bộ phần hơn nằm ở câu **không có đáp án**

- Lát cắt “cả hai cùng trả lời” **đổi dấu** theo lần chạy: 2,25 với seed 13, $-1,16$ với $lr 10^{-5}$

Điều PhoBERT làm tốt hơn là biết khi nào *không* trả lời.

Nguồn: results/diagnosis_validation.json (paired_matched_windows_tuned)

RQ1 --- Word-level có yếu ở ranh giới từ? **Không.**

	XLM-R	PhoBERT
EM, khớp biên (2.620)	52,10	67,37
EM, lệch biên (33)	45,45	30,30
F1, lệch biên	56,12	70,96
Lỗi biên / lần trả lời	26,86%	27,62%

- Cơ chế **có thật**: câu lệch biên, PhoBERT F1 cao mà EM thấp
vàng “trận Gonzales” → tại_trận → “tại trận Gonzales”
- Nhưng chỉ 33 câu, $p = 0,180$, chặn ở 0,75 điểm EM
- Khi đã trả lời, tỉ lệ lỗi biên **như nhau**
Giả thuyết ghi trước sai hướng.

Nguồn: results/diagnosis_validation.json, results/segmentation_validation.json

RQ3 --- Nhận ra câu không có đáp án? Một phần.

	Từ chối	Prec.	Recall
Luôn từ chối	100,00	30,44	100,00
XLM-R	32,96	49,48	53,57
PhoBERT	5,66	85,19	15,85

Tỉ lệ câu không có đáp án thật: 30,44%

- **XLM-R**: từ chối đúng *tần suất*, sai *đối tượng* (635 câu có đáp án bị từ chối)
- **PhoBERT**: gần như không từ chối
- Rơi vào **bẫy** của người gán nhãn: câu trả lời sai trùng đúng cụm “plausible” – PhoBERT 45,34%, XLM-R 51,39%

Nguồn: results/diagnosis_validation.json

Vì sao PhoBERT không từ chối? Một sự kiện khi huấn luyện

Huấn luyện tiếp từ epoch 1, **cùng batch**, chỉ khác lr:

Bước	lr $2,2 \cdot 10^{-5}$		lr 10^{-5}	
	loss	grad	loss	grad
1-100	0,71	25	0,69	26
401-500	0,77	30	0,68	23
501-600	2,38	12.880	0,68	23
601-700	4,23	343	0,67	58
901-1000	4,35	294	0,71	25

loss: “không có đáp án” (TB khối 100 bước); grad: chuẩn lớn nhất

- Dữ liệu hỏng? **Không**: 0 vi phạm / 31.039 feature
- Tính chất của PhoBERT? **Không**: epoch 1 từ chối 37,86% (dev)
- Bất ổn tối ưu hoá: gradient vọt **12.880**, loss “không đ.án” kẹt ở 4,35; lr 10^{-5} thì không
- Khả năng phân biệt **còn**: điểm [CLS] chỉ dịch $\approx 7,86$ logit
- **Phụ thuộc lần chạy**: seed 13, cùng lr $3 \cdot 10^{-5}$, không sụp đổ

Nguồn: results/probe_resume.json, feature_scan_phobert.json


Mọi lần chạy trên dev: $\tau = 0$ và τ hiệu chỉnh

F1 trên toàn bộ dev (1.405 câu tách từ train) – dữ liệu dùng cho mọi lựa chọn.

Lần chạy		$\tau = 0$		τ chọn trên dev		
		F1	Từ chối	τ	F1	Từ chối
XLM-R-base, seed 42	–	60,78	32,31	-0,47	61,29	25,48
XLM-R-base, seed 13	ổn định	59,67	29,61	-0,62	60,31	23,84
PhoBERT, lr $3 \cdot 10^{-5}$, seed 42	sụp đổ	61,16	7,47	7,86	68,02	27,54
PhoBERT, lr $2 \cdot 10^{-5}$, seed 42	sụp đổ	57,74	5,77	8,03	63,44	29,32
PhoBERT, lr 10^{-5} , seed 42	ổn định	60,56	20,93	-0,39	61,21	18,08
PhoBERT, lr $3 \cdot 10^{-5}$, seed 13	ổn định	68,28	25,05	1,03	69,23	30,61

Hai lần chạy sụp đổ đều là seed 42. Sau hiệu chỉnh, hai seed PhoBERT gần như trùng nhau; lr 10^{-5} ổn định nhưng còn thiếu epoch. Nhóm báo cáo **hai seed ngang nhau**.

RQ2 độ dài · RQ4 baseline · và bộ stress-test



RQ2: không suy giảm theo độ dài ngữ cảnh; đáp án dài làm giảm EM (F1 giữ nguyên) như nhau ở cả hai.

RQ4: Transformer vượt TF-IDF ở mọi nhóm; TF-IDF (EM 1,05) còn thua “luôn từ chối”.

EM trên stress-test v2 (1.139 mục)

Luôn từ chối 26,34

XLM-R 52,06

PhoBERT 49,87

TF-IDF 0,97

Mô hình vượt xa mức sàn – “luôn từ chối” 26,34 điểm. Nhóm lệch từ vựng (E4) và câu hỏi không dấu (E5) là hai chỗ sụt rõ nhất.

Kết luận

Kết luận

1. **So ở τ cố định với một seed là so hiệu chỉnh, không phải năng lực.** Seed 42, $\tau = 0$: “bằng nhau, hồ sơ ngược nhau”. Ở τ chọn trên dev: PhoBERT hơn 5,82 / 6,00 điểm EM ở hai seed.
2. **PhoBERT seed 42 “không từ chối” là một sự kiện khi huấn luyện**, tái hiện được, kèm gradient vọt; seed 13 không gặp.
3. **Không đo được khác biệt về “đọc”**: khớp cửa sổ thì chênh lệch trên câu có đáp án là -0,08 điểm. Tách từ cũng không quyết định: chỉ 1,24% đáp án cắt ngang từ.
4. **Kiểm định công cụ đo trước khi dùng**: bộ stress-test của chính nhóm xếp “không làm gì” đứng đầu.

Giới hạn

2 seed · 3 epoch, không tìm siêu tham số · pyvi thay RDRSegmenter · chưa rõ vì sao sụp đổ ở seed 42 mà không ở seed 13 · validation = public test VLSP (private test ẩn nhãn)


- Vì sao sự kiện sụp đổ chỉ xảy ra với PhoBERT; có lặp lại trên CUDA không; warmup dài hơn thay vì hạ lr
- Huấn luyện thêm epoch (XLM-R và PhoBERT lr 10^{-5} còn đang cải thiện); từ 3 seed trở lên
- PhoBERT với RDRSegmenter; sửa luật đánh dấu chấm của pyvi
- Xây lại bộ stress-test có kiểm định tự động và câu hỏi do người viết

Cảm ơn thầy và các bạn đã lắng nghe!

Mã nguồn, kết quả và nhật ký:

github.com/minhdang900/uit-benchmark-transformer-model-mrc

Phụ lục --- Quá trình huấn luyện



Chọn epoch theo **F1 trên dev** (tách từ train).

XLM-R: epoch 3, 106 phút.

PhoBERT lr $3 \cdot 10^{-5}$: epoch 3, 67 phút.

PhoBERT lr $2 \cdot 10^{-5}$: epoch 2.

PhoBERT lr 10^{-5} : epoch 3.

PhoBERT seed 13: epoch 3.

Hai seed báo cáo ngang nhau.

Phụ lục --- Độ dao động theo seed và cửa sổ

Validation, EM / F1. Seed tách dev cố định (42) để điểm dev so sánh được.

Mô hình	Seed	Cửa sổ	$\tau = 0$	τ dev
XLM-R-base	42	384/128	52,49 / 61,32	52,49 / 61,99
XLM-R-base	13	384/128	53,64 / 62,18	53,25 / 62,68
XLM-R-base	42	256/96	54,46 / 63,03	53,41 / 63,36
PhoBERT-base-v2	42	256/96	51,36 / 63,10	58,31 / 68,54
PhoBERT-base-v2	13	256/96	58,94 / 68,91	59,26 / 68,49

Nguồn: results/eval*_validation.json, results/thresholds.json