

Khảo sát và đánh giá hiệu năng các mô hình Transformer tiền huấn luyện trong bài toán đọc hiểu văn bản tiếng Việt

PhoBERT (word-level) vs XLM-R (subword) trên UIT-ViQuAD 2.0 — một
đánh giá chẩn đoán

Nguyễn Quang Lâm Trần Trọng Tấn Lê Quang Thi Võ Cẩm Thu

Tháng 9/2026

CS221 — Xử lý ngôn ngữ tự nhiên · GVHD: TS. Đặng Văn Thìn · Trường ĐH Công nghệ Thông tin, ĐHQG-HCM

Bài toán và câu hỏi

Đọc hiểu trích xuất: chỉ ra đáp án trong văn bản — hoặc từ chối

Đầu vào: đoạn văn Wikipedia tiếng Việt + câu hỏi

Đầu ra: một chuỗi con của đoạn văn, hoặc $\emptyset$

Ví dụ

“... Hà Nội là thủ đô của nước Việt Nam ...”

Hỏi: Thủ đô của Việt Nam là gì? → Hà Nội

Hỏi: GDP của Hà Nội năm 2030? → $\emptyset$ (không có đáp án)

UIT-ViQuAD 2.0: 30,44% câu validation
không có đáp án $\Rightarrow$ mô hình phải biết từ chối.

Hai họ mô hình khác nhau đứng ở khâu tách từ (Buổi 3)

PhoBERT: đơn ngữ, đầu vào đã tách từ

Hà_Nội | là | thủ_đô

XLNet-R: đa ngữ, subword trên văn bản thô

_Hà | _Nội | _là | _thủ | _đô

Mô hình word-level không thể trả lời nửa từ.

Nếu đáp án cắt ngang “Hà_Nội”, PhoBERT không có cách nào khớp chính xác.

Bốn câu hỏi nghiên cứu

	Câu hỏi	Đo bằng
RQ1	PhoBERT (word-level) có nhạy với ranh giới từ hơn XLM-R (subword)?	trần EM do biên từ · loại lỗi · so sánh cặp McNemar
RQ2	Suy giảm theo độ dài ngữ cảnh / đáp án có khác nhau?	tách nhóm theo độ dài
RQ3	Mô hình thật sự nhận ra câu không có đáp án, hay chỉ thiên lệch về từ chối?	mức sàn “luôn từ chối” · precision/recall từ chối
RQ4	Transformer có vượt baseline TF-IDF ở mọi nhóm?	so từng nhóm

Giả thuyết ghi trước (RQ1): PhoBERT yếu hơn ở ranh giới từ ghép vì lỗi tách từ lan truyền vào mô hình.

Phương pháp

Giao thức: validation chỉ được chấm một lần

Tập	Câu	Vai trò
fit (train)	27.049	huấn luyện
dev (5% đoạn văn train)	1.405	chọn epoch
validation	3.814	test, chấm 1 lần
test chính thức	7.301	ấn nhãn

- Chia theo đoạn văn; assert không đoạn văn nào dùng chung
- Stress-test chỉ để đánh giá (khung mã cũ trộn 60% vào train)
- 1 seed (42), không tìm siêu tham số

Bốn hệ thống, cùng một harness

Luôn từ chối	mức sàn
TF-IDF	truy hồi câu (Buổi 4)
XLM-R-base	fine-tune, 384 token
PhoBERT-base-v2	fine-tune, 256 token

Cùng vòng lặp, lr $3 \cdot 10^{-5}$, batch 24, 3 epoch, đáp án tối đa 64 token. Chỉ khác những gì kiến trúc bắt buộc.

Đưa PhoBERT vào bài toán trích xuất — không cần Java

PhoBERT chỉ có slow tokenizer $\Rightarrow$ **không có offset** (vị trí ký tự).

Không có offset thì không cắt được đáp án từ văn bản gốc.

Lớp SegmentedTokenizer:

1. tách từ bằng pyvi
2. căn mỗi từ về khoảng ký tự trong văn bản gốc
3. BPE từng từ; mọi mảnh mang chung khoảng của từ

Kiểm thử: giải mã nhãn ra lại đúng đáp án vàng; 25/25 dự đoán là chuỗi con sạch của ngữ cảnh.


Lỗi “sai âm thầm” đã tránh

`decode()` trả về "Hà_Nội"
chuẩn hoá xoá dấu câu $\Rightarrow$ "hànội"
so với vàng "hà nội" $\Rightarrow$ **EM 0, F1 0**

Một đáp án đúng bị chấm sai — khung mã cũ mắc lỗi này.

Kiểm định công cụ đo

Bộ stress-test 250 câu của nhóm: kiểm định trước khi dùng



15/120

câu có đáp án chứa đáp án trong ngữ cảnh

- 250 câu dùng chung 5 đoạn văn
- E5: 50 câu, 8 câu hỏi khác nhau
- “Luôn từ chối” đạt **52,00** điểm

Nguyên nhân: `_find_answer_start` trả về 0 khi không tìm thấy; ngữ cảnh gán lại theo vòng.

⇒ Không dùng để xếp hạng mô hình.

Nguồn: `results/stress_test_audit.json`

Trần EM do biên từ — đo được mà không cần mô hình

Trên 2.653 câu có đáp án của validation:

1,24%

đáp án cắt ngang một từ (33 câu)

99,25%

EM tối đa của PhoBERT hoàn hảo

Đọc từng câu lệch biên:

pyvi dính dấu chấm: CNN. 13

pyvi nối nhầm: Mỹ_Chú chuột 12

Lỗi gán nhãn: “o thời gian” 5


Ranh giới từ ghép thật: bởi_vì 3

Kênh “không trả lời được nửa từ” lấy đi tối đa 0,75 điểm EM.

Nguồn: results/segmentation_validation.json, results/misaligned_labels.json

Kết quả

Kết quả tổng — validation, 3.814 câu, chấm một lần



	EM	F1
Luôn từ chối	30,44	30,44
TF-IDF	1,05	22,11
XLM-R	52,49	61,32
PhoBERT	51,36	63,10

Chênh lệch EM tổng (cặp): **-1,13**, CI 95% [-2,88; 0,60], $p = 0,223$

⇒ Về tổng: không khác nhau có ý nghĩa.

Nguồn: results/eval*_validation.json, results/diagnosis_validation.json

Nhưng điểm tổng che hai hồ sơ kỹ năng ngược nhau

Câu có đáp án (2.653)

+14,89

EM cho PhoBERT

CI [13,08; 16,77] · 66,91 vs 52,02

Câu không có đáp án (1.161)

-37,73

EM (PhoBERT kém hơn)

CI [-40,83; -34,63] · 15,85 vs 53,57

PhoBERT đọc giỏi hơn nhiều — nhưng gần như không biết từ chối

Hai chênh lệch lớn, ngược dấu, triệt tiêu nhau trong điểm tổng. Lặp lại ở lần chạy PhoBERT thứ hai ($\ln 2 \cdot 10^{-5}$): EM có đáp án 65,21, không đáp án 13,78.

Nguồn: results/diagnosis_validation.json (McNemar + bootstrap 2.000 lần)

RQ1 — Word-level có yếu ở ranh giới từ? **Không.**

	XLM-R	PhoBERT
EM, khớp biên (2.620)	52,10	67,37
EM, lệch biên (33)	45,45	30,30
F1, lệch biên	56,12	70,96
Lỗi biên / lần trả lời	26,86%	27,62%

- Cơ chế **có thật**: câu lệch biên, PhoBERT F1 cao mà EM thấp
vàng “trận Gonzales” → tại_trận → “tại trận Gonzales”
- Nhưng chỉ 33 câu, $p = 0,180$, chặn ở 0,75 điểm EM
- Khi đã trả lời, tỉ lệ lỗi biên **như nhau**
Giả thuyết ghi trước sai hướng.

Nguồn: results/diagnosis_validation.json, results/segmentation_validation.json

RQ3 — Nhận ra câu không có đáp án? Chưa.

	Từ chối	Prec.	Recall
Luôn từ chối	100,00	30,44	100,00
XLM-R	32,96	49,48	53,57
PhoBERT	5,66	85,19	15,85

Tỉ lệ câu không có đáp án thật: 30,44%

- **XLM-R**: từ chối đúng tần suất, sai đối tượng (635 câu có đáp án bị từ chối)
- **PhoBERT**: gần như không từ chối
- Rơi vào **bẫy** của người gán nhãn: câu trả lời sai trùng đúng cụm “plausible” — PhoBERT 45,34%, XLM-R 51,39%

Nguồn: `results/diagnosis_validation.json`

Vì sao PhoBERT không từ chối? Tách loss theo loại nhãn


Loss trên 3.000 câu fit, từng checkpoint:

	Ep 1	Ep 2	Ep 3
XLM-R “không đ.án”	0,74	0,61	0,72
XLM-R vị trí đ.án	1,59	1,18	0,88
PhoBERT “không đ.án”	0,56	4,18	4,28
PhoBERT vị trí đ.án	1,35	0,88	0,63

- Loss “không có đáp án” của PhoBERT **tăng ~7 lần** sau epoch 1
 - Loss vị trí đáp án vẫn **giảm**
 - Lặp lại ở lr $2 \cdot 10^{-5}$ ($0,58 \rightarrow 4,42$)
 - Không phải mất cân bằng lớp (39,62% vs 36,56%)
- Nguyên nhân gốc: chưa xác định — cần nhiều seed.

Nguồn: `results/loss_probe.json` (`scripts/probe_loss.py`)

RQ2 độ dài · RQ4 baseline · và bộ stress-test



RQ2: không suy giảm theo độ dài ngữ cảnh; đáp án dài làm giảm EM (F1 giữ nguyên) như nhau ở cả hai.

RQ4: Transformer vượt TF-IDF ở mọi nhóm; TF-IDF (EM 1,05) còn thua “luôn từ chối”.

EM trên stress-test 250 câu

Luôn từ chối	52,00
XLM-R	51,20
PhoBERT	48,00
TF-IDF	0,00

“Không làm gì” đứng đầu — đúng như kiểm định dự báo. Bộ này không dùng để xếp hạng.

Kết luận

1. **Điểm tổng như nhau, hồ sơ kỹ năng ngược nhau.** PhoBERT: đọc giỏi hơn 14,89 điểm EM, gần như không từ chối. XLM-R: từ chối đúng tần suất, sai đối tượng.
2. **Tách từ không phải yếu tố quyết định** trên UIT-ViQuAD 2.0: chỉ 1,24% đáp án cắt ngang từ, phần lớn do lỗi pyvi.
3. **Yếu tố quyết định là một phần ba câu hỏi không có đáp án** — phải đo riêng.
4. **Kiểm định công cụ đo trước khi dùng:** bộ stress-test của chính nhóm xếp “không làm gì” đúng đầu.

Giới hạn


1 seed · không tìm siêu tham số · pyvi thay RDRSegmenter · validation làm test (test chính thức ẩn nhãn) · 256 vs 384 token

- Hiệu chỉnh ngưỡng từ chối τ trên dev — khôi phục khả năng từ chối của PhoBERT
- Tìm nguyên nhân gốc: nhiều seed, gradient theo loại nhãn, trọng số lớp, XLM-R ở 256 token
- PhoBERT với RDRSegmenter; sửa luật dính dấu chấm của pyvi
- Xây lại bộ stress-test có kiểm định tự động và câu hỏi do người viết

Cảm ơn thầy và các bạn đã lắng nghe!

Mã nguồn, kết quả và nhật ký: github.com/minhdang900/uit-benchmark-transformer-model-mrc

Phụ lục — Quá trình huấn luyện



Chọn epoch theo **F1 trên dev** (tách từ train).

XLM-R: epoch 3, 106 phút.

PhoBERT lr $3 \cdot 10^{-5}$: epoch 3, 67 phút.

PhoBERT lr $2 \cdot 10^{-5}$: epoch 2.

Lần chạy PhoBERT chính chọn theo F1 dev cao nhất.